

**EXAMEN – Session Principale**

Durée : 01H30	Matière : BIG DATA	Classe : 5 ^{ème} Génie Logiciel
Documents autorisés : NON		Enseignante : SAGAR Samya
Date : 04-01-2024		Nombre de pages : 4

Nom :Prénom :Matricule :

Note : Vous devez répondre sur cette feuille d'examen.

Partie I : QCM–Répondez par une ou plusieurs réponses.

1. **Tous les éléments suivants décrivent avec précision Hadoop, SAUF :**
 - ☐ Open source.
 - ☐ Temps réel.
 - ☐ Basé sur Java.
 - ☐ Approche de programmation distribuée.
2. **Ajouter le terme convenable dans la phrase suivante : _____ NameNode est utilisé lorsque le NameNode primaire ne fonctionne plus ?**
 - ☐ Rack
 - ☐ Data
 - ☐ Secondaire
 - ☐ Aucune des réponses précédentes
3. **Ajouter le terme convenable dans la phrase suivante : La machine _____ est un point d'échec unique pour un cluster HDFS ?**
 - ☐ DataNode
 - ☐ NameNode
 - ☐ ActionNode
 - ☐ Toutes les réponses précédentes
4. **Un cluster Hadoop est un ensemble de composants indépendants connectés via un réseau dédié pour fonctionner comme une seule ressource de traitement de données centralisée.**
 - ☐ Vrai.
 - ☐ Faux
5. **Est-il possible de fournir plusieurs entrées à Hadoop MapReduce.**
 - ☐ Vrai.
 - ☐ Faux
6. **Quel est le rôle du NameNode ?**
 - ☐ Écrire ou lire les données sur les DataNodes.
 - ☐ Vérifier la disponibilité des données sur les DataNodes.
 - ☐ Remplacer un DataNode si un d'entre eux devient indisponible.
 - ☐ Administrer les transactions en autorisant ou non la lecture / écriture des fichiers.
7. **Hadoop Framework est écrit en :**
 - ☐ Python.
 - ☐ Java.
 - ☐ C++.
 - ☐ Scala.
8. **Lequel des éléments suivants fait partie d'Hadoop ?**
 - ☐ YARN
 - ☐ HDFS
 - ☐ MapReduce
 - ☐ Tous les réponses précédentes.
9. **Quel type de données que Hadoop peut traiter ?**
 - ☐ Structuré.
 - ☐ Semi-structuré.
 - ☐ Non structuré.
 - ☐ Tout ce qui précède.
10. **Lequel des énoncés suivants est l'énoncé correct ?**
 - ☐ La localité des données signifie déplacer le calcul vers les données au lieu des données vers le calcul.
 - ☐ La localité des données signifie déplacer les données vers le calcul au lieu du calcul vers les données.
 - ☐ Les deux réponses ci-dessus.
 - ☐ Aucune de ces réponses.
11. **Lesquelles des phases suivantes se produisent simultanément ?**
 - ☐ Shuffle & Sort.
 - ☐ Reduce & Sort.
 - ☐ Shuffle & Map.
 - ☐ Toutes les réponses précédentes.

12. Le client qui lit les données du système de fichiers HDFS dans Hadoop fait quoi ?

- ☐ Obtient uniquement les emplacements de bloc du namenode.
- ☐ Obtient les données du namenode.
- ☐ Obtient à la fois les données et l'emplacement du bloc à partir du namenode.
- ☐ Obtient l'emplacement du bloc à partir du datanode.

13. Rack Awareness améliore :

- ☐ La haute disponibilité et fiabilité des données.
- ☐ Les performances du cluster.
- ☐ La bande passante réseau.
- ☐ Tout ce qui précède.

14. Lors de l'exécution de la tâche MapReduce sur quel nœud le tri est-il effect ?

- ☐ Reducer node.
- ☐ Mapper node.
- ☐ Les deux.
- ☐ Aucune de ces réponses

15. Quels sont les avantages du schéma de 3x répliquions dans Hadoop ?

- ☐ Tolérance aux pannes.
- ☐ La haute disponibilité.
- ☐ Fiabilité.
- ☐ Toutes les réponses précédentes.

16. Ajouter le terme convenable dans la phrase suivante : Un nœud _____ sert d'esclave et est responsable de l'exécution d'une tâche qui lui est assignée par le JobTracker.

- ☐ MapReduce.
- ☐ Mapper.
- ☐ TaskTracker.
- ☐ JobTracker.

17. Quelles sont les fonctionnalités de HDFS ?

- ☐ Fournit un stockage distribué
- ☐ Hautement tolérant aux pannes
- ☐ Assure la sécurité des données
- ☐ Tout ce qui précède

18. Lesquelles des affirmations ci-dessous sont vraies à propos d'un Datanode ?

- ☐ Datanode stocke les données réelles
- ☐ Datanode peut être déployé sur du matériel de base en production
- ☐ Datanode sert les requêtes de lecture et d'écriture
- ☐ Tout ce qui précède.

19. Qu'est-ce que YARN?

- ☐ Couche de stockage
- ☐ Moteur de traitement par lots
- ☐ Couche de gestion des ressources
- ☐ Aucune de ces réponses

20. Laquelle des affirmations suivantes est vraie à propos du cluster hadoop ?

- ☐ Namenode conserve les métadonnées en mémoire pour une récupération rapide
- ☐ Les datanodes servent la demande de lecture et d'écriture
- ☐ Le client obtient l'authentification du Namenode avant de commencer à lire/écrire sur les datanodes
- ☐ Tout ce qui précède

21. Hadoop peut être déployé sur des serveurs de base, ce qui permet un traitement à faible coût ainsi qu'un stockage d'énormes volumes de données non structuré.

- ☐ Vrai.
- ☐ Faux

22. Les utilisateurs peuvent contrôler le stockage de blocs sur des esclaves spécifiques?

- ☐ Vrai.
- ☐ Faux

23. Comment fonctionne la distribution de fichiers sur HDFS ?

- ☐ Répartition en fonction de la taille des fichiers sur chaque nœuds du cluster.
- ☐ Répartition en blocs répliqués sur les nœuds du cluster.
- ☐ Répartition en nœuds répliqués sur les blocs du cluster.
- ☐ Répartition en fonction des choix de l'utilisateur au moment de l'upload.

24. Ajouter le terme convenable dans la phrase suivante : _____ est le nœud esclave / travailleur et conserve les données utilisateur sous forme de blocs de données.
- ☐ DataNode
 - ☐ NameNode
 - ☐ Data block
 - ☐ Replication
25. Laquelle des affirmations suivantes est vraie à propos d'Hadoop ?
- ☐ Hadoop MapReduce traite les données à très faible latence.
 - ☐ Hadoop ne peut pas gérer les données structurées.
 - ☐ Hadoop est sans schéma - nous n'avons pas besoin de définir un schéma avant d'écrire les données.
 - ☐ Aucune de ces réponses.
26. Lequel des énoncés suivants est faux à propos d'Hadoop ?
- ☐ C'est un framework distribué.
 - ☐ Le principal algorithme utilisé dans Hadoop est Map Reduce.
 - ☐ Hadoop peut fonctionner avec du matériel de base.
 - ☐ Tous sont vrais.
27. Votre application client soumet un job MapReduce à votre cluster Hadoop. Quel est le démon sur lequel le framework Hadoop recherchera un emplacement disponible pour planifier une opération MapReduce ?
- ☐ TaskTracker
 - ☐ Secondary NameNode
 - ☐ DataNode
 - ☐ JobTracker
28. Dans un job MapReduce, un Reduce reçoit toutes les valeurs associées à la même clé. Quelle affirmation décrit le mieux l'ordre de ces valeurs ?
- ☐ Les valeurs sont triées.
 - ☐ Les valeurs sont arbitrairement ordonnées et l'ordre peut varier d'une exécution à l'autre du même job MapReduce.
 - ☐ Les valeurs sont ordonnées arbitrairement, mais plusieurs exécutions du même job MapReduce auront toujours le même ordre.
 - ☐ Étant donné que les valeurs proviennent des sorties des Maps, les Reduces recevront des sections contiguës de valeurs triées.
29. Plusieurs clients peuvent-ils écrire simultanément dans un fichier HDFS ?
- ☐ Vrai.
 - ☐ Faux
30. Vous avez écrit une classe Map qui effectue 5 appels de la méthode Output.color donnant comme résultat les couples suivants : ("Pomme", "Rouge") ; ("Banane", "Jaune") ; ("Pomme", "Jaune") ; ("Cerise", "Rouge") ; ("Pomme", "Vert"). Combien de fois la méthode Reduce sera-t-elle invoquée ??
- ☐ 6
 - ☐ 3
 - ☐ 1
 - ☐ 0
 - ☐ 5

Partie II : Exercice

Étant donné un ensemble de pages HTML, nous désirons calculer le nombre d'hyperliens entrants pour chaque URL donnée (chaque page HTML).

Exemple, supposons qu'un fichier HTML, dont l'URL est "mes.tn", apparaisse sur 3 pages : 3 fois sur la page A, 3 fois sur la page B et 4 fois sur la page C. Alors son nombre d'hyperliens entrants est dix.

1. Donnez le couple clé-valeur adapté au traitement en question.

.....
.....
.....

2. Expliquez les étapes qui seront réalisées par le mapper. Illustrez en utilisant les données en entrées et les résultats attendus (vous pouvez vous baser sur l'exemple ci-dessus)

.....
.....
.....
.....
.....
.....
.....
.....
.....
.....

